

GraphWorld: 面向人机世界共生的动态图评测基准

Author 1, *Member, IEEE*, Author 2, *Member, IEEE*, and Author 3, *Senior Member, IEEE*

摘要—现有具身智能基准大多围绕一次性任务完成展开：系统给出一个明确目标，智能体在有限 episode 内导航、抓取、开关或放置物体。真实环境具有更强的持续性，由人类活动、环境状态和机器人干预共同构成动态共生系统。本文提出 GraphWorld，一个面向人机世界共生（human-agent world symbiosis）的动态图评测基准。GraphWorld 将家庭、医院、超市、办公室和工厂等场景统一建模为持续演化的层次化场景图，其中房间、物体、设备、NPC 和机器人共享同一图结构，节点状态和空间关系会随人类日程、设备周期、环境过程和机器人动作持续变化。我们将人机世界共生定义为一种闭环状态：人类活动持续改变环境，具身智能体持续调节环境，使世界保持可用、有序，并继续支持后续人类活动。围绕这一目标，GraphWorld 提供 NPC 事件模型、动作 schema 验证、局部感知、技能条件化 agent、状态/空间/人类事件三维评分，以及多场景、多难度、多日程扰动的实验协议。实验表明，机器人干预通常显著优于无机器人基线，但现有 LLM agent 仍容易被局部可见偏离吸引，缺少稳定的长期任务调度能力。GraphWorld 的意义在于把具身智能评测从完成孤立指令推进到维持人、机器人与动态世界之间的长期共生闭环。

Index Terms—具身智能，人机共生，动态图世界，场景图，长时程规划，服务机器人。

I. 引言

当前 Embodied AI 的主流评测通常默认任务是有限的。无论是导航、抓取、语言条件操作，还是更复杂的长程任务分解，系统往往给定一个初始状态、一个目标和一个终止条件，智能体的能力由其能否在有限步内完成目标来衡量。这种设定推动了感知、导航和短程规划的发展，但它与真实部署环境之间仍存在一个关键断裂：真实世界不会在机器人完成一次任务后停止变化。

家庭、医院、超市、办公室和工厂都具有同一个更一般的结构：人类活动不断改变环境，而环境状态又反过来决定后续人类活动是否顺利。衣服会被穿走并变脏，杯子和餐具会被拿出、使用并留下清洗需求；医院的处方、药品、病床、床单和医疗垃圾会随病人、护士和医生流程不断变化；超市货架、购物车、冷柜和收银区会被顾客和员工共同扰动；办公室的会议室、文件、茶水

间和打印设备需要在工作流之间被恢复；工厂中的安全装备、零件箱、机器、工具和质检记录形成生产流程中的状态压力。这些问题共同指向同一个持续闭环：人类活动改变环境，机器人调节环境，环境继续支持后续人类活动。

本文将这一类问题称为人机世界共生（human-agent world symbiosis）：给定一个会被人类活动持续扰动的动态场景图，具身智能体如何通过长期调节环境，使世界保持可用、有序，并持续支持人类日常或职业活动。这个问题的重点是机器人能否在不断出现的多类环境偏离之间选择、排序、坚持、切换和恢复任务。任务流程可以作为操作先验，真正需要评估的是共生闭环中的长期调度能力。

这一视角把具身评测重新组织为三个核心对象。第一，环境是一个动态运行时世界，场景图随时间、人类事件、设备周期和机器人动作持续演化。第二，任务来自世界的熵增，人类使用环境后留下状态偏离、空间偏离和流程阻塞，机器人需要从这些环境偏离中选择行动目标。第三，评价指标来自世界本身：状态健康、空间秩序和人类事件成功率共同刻画人、机器人与环境之间的共生闭环是否稳定。

GraphWorld 正是围绕这一问题构建的动态图世界基准。它把场景表示、NPC 日程、设备过程、机器人动作和评分机制统一在一个层次化场景图中。与只把场景图作为感知或规划输入不同，GraphWorld 中的图是运行时世界底座：节点状态会被事件修改，物体位置会被人类和机器人移动，设备周期会随时间推进，机器人只能通过局部感知逐步发现世界。由此，环境本身持续制造待恢复偏离，机器人行为则被评价为对人类活动-环境状态闭环的调节能力。

本文贡献如下：

- 我们提出并形式化了人机世界共生这一新评测问题，将具身智能从完成孤立任务推进到持续人类扰

动下的人机-环境闭环调节。

- 我们构建了 GraphWorld benchmark, 包括动态运行时场景图、NPC 扰动引擎、动作 schema、局部感知、多场景生成, 以及状态、空间和人类事件三维评分。
- 我们通过主实验、多样性实验和日程随机性实验发现, 现有 LLM agent 虽能改善世界状态, 但仍缺少稳定的全局任务调度能力, 容易被局部可见偏离吸引。

II. 相关工作

A. 具身任务完成基准

已有具身智能基准主要关注给定任务能否完成。语言导航、对象操作和家庭任务基准通常将每个 episode 组织为一个明确目标, 智能体在有限时间内完成导航、抓取、放置或开关动作。这类基准适合评估感知、grounding 和短程执行, 但其任务边界通常由外部给出, 环境在 episode 内的变化也主要服务于该任务。GraphWorld 关注另一类问题: 人类活动持续改变世界, 机器人需要从状态偏离、空间偏离和流程压力中自主组织任务。

B. 场景图与语义世界表示

场景图和语义地图为机器人提供了结构化环境表示。Hydra 研究实时 3D 场景图构建和优化 [1], SayPlan 将 3D 场景图用于大规模语言模型规划 grounding [2], Taskography 从任务规划角度评价大规模 3D 场景图 [3]。这些工作说明图结构能够表达空间层次、对象关系和任务上下文。GraphWorld 继承这种结构化优势, 但进一步把图变成运行时世界: 节点状态、空间关系和事件日志会在每一步被更新, 并直接参与动作合法性和长期评分。

C. 长程规划与语言模型机器人

SayCan、Inner Monologue 等方法将语言模型与可供性、环境反馈或中间推理结合, 用于长程任务分解和动作选择 [4], [5]。它们通常从给定指令出发, 将任务拆分为可执行技能。GraphWorld 的关注点更靠前: 在持续变化的世界中, 哪些任务值得做, 何时继续当前目标, 何时切换到更紧急的环境偏离, 任务做一半后如何恢复。这使得语言模型不只是任务分解器, 而是人机世界共生闭环中的环境调节策略。

D. 人类活动与持续世界

Generative Agents 等系统展示了长期运行的人类角色、日程和社会行为 [6]。这类工作启发我们将 NPC 视为世界动力学的一部分, 而非静态背景对象。但机器人评测需要更明确的可执行状态: 门是否打开、杯子是否有水、药品是否在冷藏处、衣服是否湿、垃圾桶是否满。GraphWorld 因此将人类活动转化为可验证、可恢复、可评分的图状态变化。

III. 方法

A. 问题定义: 人机世界共生

我们将世界表示为随时间演化的动态图:

$$\mathcal{G}_t = (\mathcal{V}, \mathcal{E}^s, \mathcal{E}_t^d, \mathcal{X}_t, \mathcal{H}_t), \quad (1)$$

其中 $\mathcal{V}$ 是房间、物体、设备、人类和机器人节点集合, $\mathcal{E}^s$ 是稳定结构边, $\mathcal{E}_t^d$ 是运行时动态关系, $\mathcal{X}_t$ 是节点状态, $\mathcal{H}_t$ 是世界时间、事件日志和可见性上下文。人类活动过程 P_h 持续扰动图, 机器人策略 π 基于局部观察 o_t 和内部目标记忆 m_t 选择动作:

$$a_t \sim \pi(o_t, m_t). \quad (2)$$

人机世界共生的目标是在长时程内最大化环境对持续人类活动的支持能力:

$$\max_{\pi} \frac{1}{T} \sum_{t=1}^T U(\mathcal{G}_t), \quad (3)$$

其中 U 同时度量状态健康、空间秩序和人类活动支持程度。

B. 动态图世界

GraphWorld 的节点包括 room、fixed object、movable object、control object、human 和 robot。结构关系描述房间连通、容器包含、设备控制和固定支撑; 动态关系描述物体当前位姿, 例如 in、on、near、held_by 和 worn_by。状态空间只保留预定义离散或数值状态, 例如 is_dirty、is_open、is_on、is_wet、folded、is_rotten、temperature、fill_level 和 remaining_cycle。

场景构建采用静态图变体。每个 base scene 可以生成不同 topology 和 object-interaction profile: compact_cleaning 让关键物体更集中并突出清洁需求; normal_logistics 保持正常拓扑并突出搬运、

归位和补给; spread_device 拉远关键房间和设备, 强调设备链和跨房间依赖。这样, 同一场景类型可以产生不同难度, 而不必依赖新的场景类别堆叠。

C. 人类事件模型

NPC 是 GraphWorld 的核心扰动源。每个 NPC 由角色、日程和事件序列定义。事件包含前置条件和效果: 前置条件判断人类活动能否成功, 效果将活动结果写回图状态。例如病人取药要求处方和药盒存在; 护士送药会移动冷藏药; 工厂工人准备上岗会取走安全装备; 顾客购物会移动商品、使用购物车并影响冷柜或收银区状态。

我们用五类活动驱动描述 NPC 行为来源: bodily_need、health_safety、role_duty、social_coordination 和 creative_improvement。这些类别用于解释不同场景中人类为什么持续使用和扰动环境。家庭主要由 bodily need 驱动, 医院和工厂强调 health safety 与 role duty, 办公室和超市则更多体现 social coordination 与流程服务。

D. 动作 Schema 与合法性

机器人动作采用 PDDL 风格的 action schema:

$$\text{schema} = (\text{parameters}, \text{preconditions}, \text{effects}). \quad (4)$$

当前动作空间包括 move、pick、place、open、close、press、brush、fold 和 dump。合法性检查与效果执行分离: predicate 只判断同房间、手持物、容器可访问、容量、设备门、动作 affordance 等条件; effect 只执行移动节点、开关、清洁、折叠、倒空和设备启动等状态更新。这种边界避免把动作语义、物体规则和运行时副作用混在同一段逻辑中。

动作规则显式阻止不合理捷径。例如布类物体不能通过普通 brush 直接清洁, 必须经过洗衣机、晾衣架、折叠和收纳; 垃圾桶只接收腐烂或烧焦食物, 并需要在垃圾站 dump 后恢复; 杯子有液体时需要在水槽倒空; 设备门未关闭时不能启动周期。这些约束保证 agent 不能靠非法或过度简化动作刷分。

E. Agent 方法

我们比较四类方法。No-robot 只运行 NPC 和环境转移。Reactive agent 只根据局部观察、最近分数和合法

动作空间进行一步反应。Single-round agent 在一次 LLM 调用中同时选择高层任务和低层动作。Goal-review agent 先判断是否继续、切换、完成或放弃当前 active goal, 再选择低层动作。

GraphWorld 中的技能库作为 procedural prior 使用。洗衣、倒垃圾、补药、归还冷藏药、整理购物车、归档文件和归还 PPE 等流程具有相对固定的正确阶段; 真正的研究问题是机器人是否知道什么时候启动该流程、是否坚持执行、是否在新扰动出现时切换, 以及任务中断后能否恢复。因此, 技能库定义“决定做某类待恢复状态后怎么做”, 而实验评估“在持续扰动世界中该先做什么、做到何时、何时切换”。

F. 评分

GraphWorld 使用三类分数。状态分数衡量对象状态是否健康:

$$S_{\text{state}}(t) = 1 - \frac{\sum_{i,j} M_{ij} d(X_{ij,t}, X_{ij,t}^*)}{\sum_{i,j} M_{ij}}, \quad (5)$$

其中 M 是状态 mask, 只统计该对象实际拥有的状态维度。空间分数衡量可移动物体是否处于合理关系:

$$S_{\text{spatial}}(t) = 1 - \frac{1}{|\mathcal{O}|} \sum_{o \in \mathcal{O}} \mathbf{1}[r_t(o) \neq r_t^*(o)]. \quad (6)$$

人类事件分数衡量 NPC 日程事件是否成功:

$$S_{\text{human}}(t) = \frac{N_{\text{success}}(1:t)}{N_{\text{attempt}}(1:t)}. \quad (7)$$

综合分数为

$$S(t) = 0.45S_{\text{state}}(t) + 0.35S_{\text{spatial}}(t) + 0.20S_{\text{human}}(t). \quad (8)$$

实验同时记录 instant score 和平均曲线。Instant score 展示当前世界状态, 平均曲线展示长期共生闭环的稳定性。

IV. 实验

A. 实验设置

我们在五个 base scenes 上实验: 家庭、医院、超市、办公室和工厂。家庭包含 1 个 resident; 其余场景包含 3 个 NPC, 分别覆盖病人/护士/医生、顾客/收银员/理货员、员工/经理/访客、工人/质检员/维修员。所有主实验运行 1600 step, 机器人设置为 1 个机器人, LLM 使用 Qwen3.5-9B。

实验分三组。主实验评估 5 个 base scene、固定日程和 4 种方法。多样性实验评估 5 个场景、3 种 graph profile 和 no-robot/goal-review 两种方法。日程随机性实验评估 5 个 base scene、fixed/calendar/stochastic 三类日程和多种方法。三组实验分别回答方法是否有效、场景难度变化是否可区分、以及人类扰动模式变化是否影响结果。

B. 主实验：Agent 是否能稳定共生闭环

图 1 展示 base graph 上的主实验曲线。总体上，带任务结构的 agent 明显优于无机器人基线，尤其在 office 和 factory 等空间秩序强依赖场景中提升显著。表 I 给出最终分数。Single-round 在 home、supermarket、office 和 factory 中取得最高 final score；goal-review 在 hospital 中表现最好。这说明二次 goal review 并非总是更强，它在流程依赖强的医院中有优势，但在一些场景中会被局部目标反复吸引，反而不如一次性选择高层任务和低层动作。

更细地看，三类分数揭示了 agent 改善世界的不同机制。Home 中 single-round 同时提高 spatial 和 human score，说明它不仅把物体放回合理位置，也恢复了后续人类事件需要的衣物、餐具和垃圾处理条件。Hospital 中 goal-review 的提升主要来自 spatial score 从 0.282 提高到 0.711，并伴随 human score 提升，说明医院场景的关键不是单个状态清洁，而是处方、药品、病床和医疗垃圾等对象是否回到流程可用位置。Office 和 factory 中 single-round 的优势更明显地体现在 spatial score：它能快速归还文件、工具、PPE 和零件箱，使人类职业流程恢复可用。Reactive 虽然有时能维持较高 state score，但缺少跨房间归位和流程恢复能力，因此 final score 可能低于 no-robot。

这一结果也解释了为什么 GraphWorld 需要拆分指标。不同 agent 的表面分数可能接近，但其行为机制不同：有的主要清洁局部状态，有的主要恢复空间秩序，有的能支撑人类事件继续发生。三维评分使这些差异可以被拆开观察，避免被单一 success rate 掩盖。

C. 模型主干补充实验：同一策略是否受模型能力影响

除 1600 step Qwen3.5-9B 主实验外，我们进一步在相同五个 base scenes 上运行 800 step 模型对比实验，比较 Qwen3.5-9B 与 DeepSeek-R1-Distill-Qwen-14B 在 reactive、single-round 和 goal-review 三种机器人策略下

的表现。图 2 展示最终综合分对比，灰色虚线为对应场景的 no-robot 基线。表 II 汇总跨场景平均分。

结果显示，reactive 方法对模型能力不敏感，两个模型相对 no-robot 的平均提升都很小，说明局部可见图和合法动作候选不足以形成长期维护策略。Single-round 在两个模型上都稳定提升，表明显式输出高层任务与低层动作已经能利用图状态中的长期异常。Goal-review 对模型能力更敏感：Qwen3.5-9B 平均提升为 +0.1213，而 DeepSeek-R1-14B 达到 +0.1946，是该补充实验中的最佳结果。这说明当策略被拆成“是否继续当前目标”和“下一步动作选择”两个层次后，更强的模型更能保持长链任务上下文，减少过早切换目标和重复局部动作。

D. 多样性实验：Graph Profile 是否拉开难度

图 3 展示三种 graph profile 的结果。多样性实验验证了两个点。第一，no-robot 随着任务物体压力增加而明显下降，尤其在 hospital、supermarket、office 和 factory 中，spread/device profile 更容易积累状态偏离和流程阻塞。第二，goal-review 大多数情况下高于 no-robot，说明 agent 对共生闭环的调节能力不是只对一个固定 base graph 有效。

但这组实验也暴露了短板。Factory spread 中 goal-review 仅从 0.391 提升到 0.465，远低于 normal profile 中的 0.202 提升；hospital normal 中提升也只有 0.052。轨迹统计显示，factory spread 中机器人执行了 980 次 brush，其中 973 次集中在 table_break_room，导致它没有充分处理 PPE、零件箱、设备链和质检记录等更高价值的流程目标。hospital normal 中机器人 1518 次为 move，长期围绕 locker_staff_room 和 staff room 局部目标移动，未能稳定推进药品、处方、病床和医疗垃圾闭环。

因此，graph profile 的作用在于改变 agent 面临的调度结构，而非简单增加物体数量。compact_cleaning 主要考察局部清洁和短链恢复，agent 往往容易得到稳定收益；normal_logistics 考察跨房间搬运和补给，要求 agent 在多个对象之间排序；spread_device 引入更远拓扑和设备依赖，要求 agent 完成长链流程。Factory spread 的失败说明，当任务需要从局部清洁转向生产链恢复时，当前 LLM agent 很容易停留在“看见什么修什么”的策略层级，而没有形成面向流程的全局优先级。




图 1. Base scene 主实验曲线。列为场景，行为 final/state/spatial/human 四类分数。

E. 日程随机性实验：扰动模式是否影响方法表现

图 4 展示 stochastic schedule 下的方法对比。补充方法实验显示，日程扰动会改变环境偏离累积轨迹，但不是所有场景都同样敏感。Home 的 stochastic 设置中 goal-review 明显高于 no-robot，而 single-round 低于 no-robot，说明家庭中错误任务选择会直接破坏人类事件链。Office 和 factory 中 single-round 在 final score 上高于 goal-review，主要来自空间恢复分数更高；goal-review 虽然也显著优于 no-robot，但更容易在局部目标 review 中保守切换。

这一结果说明，GraphWorld 不只是证明某个 agent 更强，也能揭示方法结构的失败模式。Reactive 通常只能修补局部状态，难以恢复空间链；single-round 在部分场景中更果断，能快速选择高价值空间目标；goal-review 对长期目标有帮助，但如果 review 机制没有显式任务优先级，就可能被反复出现的小环境偏离吸住。

从日程角度看，场景敏感性与人类流程的耦合程度有关。Home、hospital 和 factory 对事件顺序更敏感，因

为穿衣、取药、上岗、生产和质检都依赖前序对象是否可用；一旦机器人错过恢复窗口，后续事件会连续失败。Supermarket 和 office 的部分活动更像可并行服务流，单个事件失败不一定立即阻断全天流程，因此曲线更平滑。这个现象说明，GraphWorld 的随机日程用于区分“局部修补型 agent”和“能理解流程依赖的 agent”。

F. Agent 行为模式

除了分数曲线，我们进一步统计不同方法的动作分布和目标选择。图 5 展示了方法级动作画像。Reactive 更偏向局部 brush、close 和短距离 move，这与其缺少高层任务结构一致。Single-round 的 pick/place 比例更高，说明它更常进入搬运和归位流程。Goal-review 理论上应增强长期目标坚持，但实际轨迹显示，它也可能在 review 阶段频繁切换，尤其当当前可见目标语义明确但价值较低时。

我们观察到三种稳定模式。第一，空间恢复优先：agent 更容易理解“物体应放回哪里”，因此 spatial score 往往比 state score 更容易被拉开。第二，状态流程断裂：

表 I

BASE SCENE 1600 STEP 长期运行结果。F/S/Sp/H 分别表示综合分、状态分、空间分和人类事件分。绿色表示该场景综合分最高的方法；红色表示综合分低于无机器人基线。

场景	no-robot				reactive				single-round				goal-review			
	F	S	Sp	H	F	S	Sp	H	F	S	Sp	H	F	S	Sp	H
家庭	0.780	0.889	0.605	0.843	0.755	0.834	0.605	0.841	0.892	0.893	0.874	0.921	0.854	0.865	0.800	0.921
医院	0.677	0.907	0.282	0.852	0.652	0.870	0.281	0.811	0.670	0.907	0.282	0.815	0.847	0.925	0.711	0.911
超市	0.769	0.892	0.730	0.563	0.779	0.946	0.737	0.477	0.948	0.906	0.975	0.993	0.929	0.903	0.949	0.954
办公室	0.626	0.899	0.341	0.510	0.658	0.974	0.337	0.510	0.952	0.981	0.968	0.860	0.892	0.956	0.885	0.758
工厂	0.645	0.927	0.505	0.254	0.614	0.937	0.406	0.254	0.886	0.948	0.986	0.575	0.856	0.943	0.956	0.485

Model comparison by scene and robot policy




图 2. 800 step 模型主干对比实验。柱状图为机器人策略在不同模型下的最终综合分，灰色虚线为对应场景的无机器人基线。

表 II

五个场景上的 800 STEP 平均最终综合分。 Δ 表示相对无机器人基线的平均提升；无机器人基线平均最终综合分为 0.5184。

策略	Qwen3.5-9B		DeepSeek-R1-14B	
	分数	Δ	分数	Δ
Reactive	0.5323	+0.0139	0.5257	+0.0073
Single-round	0.6748	+0.1564	0.6808	+0.1624
Goal-review	0.6397	+0.1213	0.7130	+0.1946

洗衣、冷链、设备运行、床单更换和生产质检都需要多步动作与时间过程，agent 一旦中途切换，state score 就长期无法恢复。第三，局部目标吸引：模型倾向选择最近、最显眼、动作结果最确定的目标，例如桌面、柜门、按钮和当前房间对象。这些模式解释了为什么机器人能

显著改善世界，但仍没有达到稳定共生。

G. 失败分析：为什么现有 Agent 仍然不够

当前最明显的失败来自局部可见偏离吸引。LLM 在每一步看到合法候选和可见状态时，很容易选择最近、最确定、语义最直接的动作，例如清洁当前房间的桌子、关闭当前可见柜子或移动到最近控制物。只要 NPC 事件持续制造这些局部可见偏离，agent 就会反复处理低价值任务，而忽略跨房间、跨设备、跨人类事件的长链任务。

第二个失败来自状态偏离和空间偏离的不同步。机器人很擅长把物体归位，因此 spatial score 往往被拉高；但 state score 需要完成设备链、等待周期和后续收纳，例如洗衣、冷链、机器运行和床单更换。若 agent 不能




图 3. Graph 多样性实验。虚线为 no-robot，实线为 goal-review；颜色表示 compact、normal 和 spread 三种 profile。

保持任务阶段，它可能完成一半流程后切走，导致状态偏离长期存在。

第三个失败来自缺少显式全局任务队列。当前 active goal 是局部记忆，而不是一个可排序、可抢占、可恢复的任务池。更合理的下一步是把每个待恢复任务实例化为 task object，记录其价值、紧急度、距离、依赖、预计耗时和对 human event 的影响，再由调度器选择技能流程。

这些失败并不是简单的模型不够大。即使给定技能库和合法动作空间，agent 仍然需要判断任务价值、流程阶段和切换时机。换言之，GraphWorld 将问题从“能否生成合法动作”推进到了“能否在动态世界中组织长期行为”。这也是我们认为该 benchmark 有研究价值的地方：它把 LLM agent 的短程常识能力和长期调度能力分离开来，使后者成为可以被系统测量的问题。

V. 讨论

GraphWorld 的核心是把已知技能放到持续扰动世界里，评估 agent 是否能长期调度它们。因此，技能库将评测焦点从“模型是否知道洗衣常识”转移到“模型能否在多类环境偏离之间进行长期共生调节”。在这个

意义上，未来可以加入 oracle skill upper bound：若完美调度且完美执行所有技能，分数上界是多少；再将 LLM agent 与该上界比较，区分场景/评分问题和 agent 调度问题。

多场景设计服务于同一个抽象问题。Home、hospital、supermarket、office 和 factory 分别代表生活秩序、健康安全流程、零售补给、协作信息流和生产流程。未来加入 warehouse 或 greenhouse 时，也应按同一抽象扩展：仓储调节库存、通道和拣货流；农业大棚调节作物状态、温湿度、灌溉和工具流程。这样 GraphWorld 可以作为 human-agent world symbiosis 的统一基准，而不局限于某个单一 domain 的任务集。

当前限制主要有三点。第一，NPC 事件仍带有模板化设计，一些事件会持续制造局部状态偏离，可能过强地吸引 agent。第二，评分中的合理状态仍主要基于稳态目标，未来需要更多 activity-conditioned target，例如吃饭时餐具在桌上是合理的，饭后才成为待恢复状态。第三，多机器人虽然在数据结构上可表示，但缺少强仲裁和资源 claim 机制，尚不能系统研究多机器人协同调节。




图 4. Stochastic schedule 下四种方法对比。灰色虚线为 no-robot, 红色为 reactive, 黄色为 single-round, 蓝色为 goal-review。

VI. 结论

本文提出 GraphWorld, 一个面向人机世界共生的动态图评测基准。GraphWorld 将具身智能评测从完成孤立指令推进到在持续人类扰动下调节多样化动态世界。通过层次化场景图、NPC 事件、动作 schema、局部感知、技能条件化 agent 和三维长期评分, GraphWorld 能够系统分析机器人如何调节状态健康、空间秩序和人类活动支持能力。五个场景、三类 graph profile 和多种日程扰动的实验表明, 现有 LLM agent 能显著改善世界状态, 但仍缺少稳定的全局任务调度能力。我们认为, 人机世界共生将成为服务机器人从单次任务执行走向长期共处的重要评测方向。

参考文献

- [1] K.-M. et al., “Hydra: A real-time spatial perception system for 3d scene graph construction and optimization,” *arXiv preprint arXiv:2201.13360*, 2022.
- [2] S. Vemprala et al., “Sayplan: Grounding large language models using 3d scene graphs for scalable robot planning,” in *Conference on Robot Learning*, 2023.
- [3] A. Bagaria et al., “Taskography: Evaluating robot task planning over large 3d scene graphs,” *arXiv preprint arXiv:2207.05006*, 2022.
- [4] M. Ahn et al., “Do as i can, not as i say: Grounding language in robotic affordances,” *arXiv preprint arXiv:2204.01691*, 2022.
- [5] W. Huang et al., “Inner monologue: Embodied reasoning through planning with language models,” *arXiv preprint arXiv:2207.05608*, 2022.
- [6] J. S. Park et al., “Generative agents: Interactive simulacra of human behavior,” *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*, 2023.




图 5. 不同方法的动作画像。动作分布揭示了方法的行为偏好：reactive 更偏局部修补，single-round 更常执行搬运归位，goal-review 在部分场景中会因目标复审而频繁切换。